

Expose

**Parallelisierung einer speichereffizienten  
Approximation der LZ77-Faktorisierung**

Gajann Sivarajah

Gutachter:

Patrick Dinklage

Name des Zweitgutachters

Technische Universität Dortmund

Fakultät für Informatik

LS-11

<https://afe.cs.tu-dortmund.de>



# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
1.1	Motivation und Hintergrund . . . . .	1
1.2	Ziele und Methodik . . . . .	1
<b>2</b>	<b>Arbeitsplan</b>	<b>3</b>
2.1	Dokumentation . . . . .	3
2.2	Zeitplan . . . . .	4
<b>3</b>	<b>Textbaustein - LZ77</b>	<b>5</b>
3.1	Familie der LZ77-Algorithmen . . . . .	5
3.2	Konzept . . . . .	5
3.2.1	Definitionen . . . . .	5
3.2.2	Algorithmus - Kompression . . . . .	5
3.2.3	Algorithmus - Dekompression . . . . .	6
3.3	Beispiel . . . . .	7
3.3.1	Uniforme Zeichenfolge . . . . .	7
3.3.2	Zeichenfolge mit Varianz . . . . .	7
	<b>Literaturverzeichnis</b>	<b>10</b>



# Kapitel 1

## Einleitung

### 1.1 Motivation und Hintergrund

Die Produktion, Verbreitung und Nutzung digitaler Technologie hängt im hohen Maße von der Fähigkeit ab, große Mengen an Daten speichern, transportieren und analysieren zu können. Der Umgang mit großen Datenmengen geht jedoch mit entsprechend hohen Kosten einher. Ein wichtiges Werkzeug zur Bewältigung dieses Problems sind Kompressionstechniken, die Relationen und Redundanzen in Datenmengen extrahieren, um ihre Größe möglichst auf ihre inhärente Komplexität zu reduzieren. Im Laufe der Zeit wurden zahlreiche Kompressionsalgorithmen entwickelt, die wiederum über mehrere Iterationen verbessert wurden. Viele solcher Kompressionstechniken können der Familie der LZ77-Algorithmen zugeordnet werden, wobei diese sich in Statistiken, wie der Laufzeit, der Speicheranforderung oder Kompressionsrate unterscheiden.[12] In [7] wird eine Variante der LZ77-Faktorisierung beschrieben, die über 3 Phasen eine 2-Approximation einer exakten LZ77-Faktorisierung[6] erreichen kann. Diese beschränkten Einbußen in der Qualität der Ausgabe werden jedoch dadurch kompensiert, dass der Algorithmus die Speicheranforderung weit unterbieten kann. In dieser Arbeit fokussieren wir uns auf die Laufzeit des Algorithmus. Das Ziel dieser Arbeit soll die Verbesserung der Laufzeit durch eine Parallelisierung der approximativen LZ77-Faktorisierung im SIMD(Single Instruction, Multiple Data)-Modell sein.

### 1.2 Ziele und Methodik

Im Rahmen der Parallelisierung des approximativen LZ77-Algorithmus werden wir zunächst und hauptsächlich die erste Phase des Algorithmus dahingehend anpassen, dass mehrere Threads im shared-memory-Modell konfliktfrei auf Daten zugreifen und eine korrekte Ausgabe liefern können. Im Rahmen der praktischen Evaluation der beschriebenen Konzepte wird eine Implementierung in C++ herangezogen. Die Parallelisierung wird hauptsächlich über Instruktionen im OpenMP-Schema[4] realisiert, wobei alternative Kon-

zepte, wie *execution policies*[5] aus der Standardbibliothek auch in Erwägung gezogen werden können. Der parallele Zugriff auf Datenstrukturen wird eine besondere Schwierigkeit sein. Hier werden verschiedene Techniken untersucht und ein Blick auf bereits vorhandene Lösungen[3] geworfen. Als Bewertungsmaßstab werden verschiedene Statistiken, unter Anderem die Laufzeit, die Speichenanforderung, sowie die Qualität der Kompression gemessen. Da hier nur die erste Phase berücksichtigt wird, soll die Qualität der Kompression anhand der Zahl der Faktoren bemessen werden, die aus der Eingabe extrahiert wird. Wir werden grundlegend voraussetzen, dass jegliche Anpassungen am Algorithmus keinen negativen Einfluss auf die Kompressionsqualität bzw. der Anzahl der Faktoren haben darf. Neben dem sequenziellen approximativen LZ77-Algorithmus sollen die Statistiken mit Messungen anderer Kompressionsalgorithmen, wie LZW[11] und dem exakten LZ77, verglichen werden. Für die Testeingabe wird der Canterbury Corpus[1] herangezogen.

# Kapitel 2

## Arbeitsplan

### 2.1 Dokumentation

1. Einleitung
2. Theoretische Grundlagen
  - Definition
  - Sätze(rekursive Hashfunktion,etc)
  - (exakte) LZ77-Faktorisierung
  - Approximative LZ77-Faktorisierung(seq)
3. Parallele approximative LZ77-Faktorisierung - Konzept
  - Korrektheitsbeweis
  - Theoretisches Laufzeitverhalten und Speicheranforderung
4. Praktische Evaluation
  - Definition der Testumgebung
  - Beschreibung der Implementation
  - Grafische Aufarbeitung von Metriken(Laufzeit, Speicher, Faktorzahl)
  - Bewertung der Ergebnisse
5. Fazit und Ausblick

## 2.2 Zeitplan

Der Zeitplan sieht 4 Phasen vor, die wiederum einen Kreislauf aus **Konzept**  $\Rightarrow$  **Implementierung**  $\Rightarrow$  **Evaluation**  $\Rightarrow$  **Konz...** darstellen. Im Folgenden ist der chronologische Zeitplan (Annahme: 16 Wochen stehen zur Verfügung) zu sehen. [ToDo: Grafik]

<b>Zeitraum</b>	<b>Phase</b>	<b>Treffen mit Betreuer</b>
W1-W2	Framework mit Referenz-Algorithmen	W2
W3-W4	Approx. LZ77(seq)	W3, W4
W5-W8	Approx. LZ77(par)	W5, W7, W8
W9-W12	Dokumentation und Optimierung	W10, W12
W13-W15	Präsentationsvorbereitung	W14, W15



# Kapitel 3

## Textbaustein - LZ77

### 3.1 Familie der LZ77-Algorithmen

Im Jahr 1977 beschrieben Abraham Lempel und Jacob Ziv erstmals eine Methode zur Textindizierung, die es erlaubt Folgen von Datenzeichen dynamisch zu komprimieren ohne ihren Kontext vorher zu kennen. Der Grundbaustein des Algorithmus ist die Generation von Faktoren, welche Teilfolgen sind, die bereits vorher in der Zeichenfolge aufkommen. Diese Faktoren können anschließend durch Referenzen auf ihre vorherigen Vorkommen ersetzt werden. Bis heute findet man zahlreiche Varianten und Weiterentwicklungen dieser Grundidee, wie z.B. im GZIP-Format(DEFLATE)[2].

### 3.2 Konzept

#### 3.2.1 Definitionen

Unsere Eingabe sei eine  $n$ -elementige Zeichenfolge  $S = e_1 \dots e_n$ , die über einem beschränkten numerischen Alphabet  $\Sigma$  konstruiert wurde. Für eine Zeichenfolge  $S$  gibt der Ausdruck  $|S|$  die Länge, hier  $n$ , an. Der Ausdruck  $S[i..j]$  mit  $i, j \in [1, n]$  und  $i \leq j$  beschreibt die Teilfolge  $e_i \dots e_j$ , wobei im Falle, dass  $i = j$  gilt, das einzelne Zeichen  $e_i$  referenziert wird. In diesem Fall kann der Ausdruck  $S[i..i]$  durch  $S[i]$  ersetzt werden. Ein Präfix von  $S$  ist jede Teilfolge, die durch den Ausdruck  $S[1..k]$  mit  $k \leq n$  referenziert wird. Eine LZ77-Faktorisierung von  $S$  ist eine Partitionierung von  $S = e_1 \dots e_n$  zu  $S = f_1 \dots f_z$  mit  $z \in \mathbb{N}$  und  $z \leq n$ . Jeder Faktor stellt dabei entweder ein einzelnes Zeichen oder eine Referenz auf eine vorherige Teilfolge dar.

#### 3.2.2 Algorithmus - Kompression

In 3.1 wird der sequenzielle und deterministische Prozess der Faktorisierung beschrieben. Ein referenzierender Faktor ist eindeutig durch seine Zielposition, der Länge der Übereinstimmung und dem darauf folgenden Zeichen bestimmt. Das Folgezeichen erhält seine

```

1:  $S \leftarrow \text{input}$ 
2:  $\text{output} \leftarrow \text{EmptyQueue}$ 
3:  $i \leftarrow 1$ 
4: while  $i \leq n$  do
5:    $[\text{pos}, \text{len}] \leftarrow \text{longestPreviousMatch}(S[\text{pos}..\text{pos} + \text{len}] = S[i..i + \text{len}])$ 
6:    $\text{Append}\{\text{pos}, \text{len}, S[i + \text{len}]\}$  to output
7:    $i \leftarrow i + 1$ 
8: end while
9: return output

```

**Algorithmus 3.1:** LZ77-Compression

Bedeutung aus dem Szenario, dass das aktuelle Zeichen kein vorheriges Vorkommen hat. In diesem Fall werden die Position und die Länge auf den Wert 0 normiert. Bei der Extraktion der längsten übereinstimmenden Zeichenfolge entsprechend der Zeile 5 kann der sichtbare Bereich vor und nach dem aktuellen Zeichen in seiner Größe beschränkt werden. Führt man diese Beschränkung nicht ein, so bezeichnet man die resultierende Faktorisierung als **exakt**. In [6] wird ein Algorithmus zur Generation einer exakten LZ77-Faktorisierung in  $O(n)$  Laufzeit beschrieben. Für die Extraktion von Übereinstimmungen nutzt der Algorithmus ein Suffix-Array, welches jedoch beträchtliche  $= O(n)$  an Speicherplatz belegt.

### 3.2.3 Algorithmus - Dekompression

```

1:  $\text{input} \leftarrow \{f_1, \dots, f_z\}$ 
2:  $\text{output} \leftarrow \text{Empty String}$ 
3:  $i \leftarrow 1$ 
4: for  $i$  from 1 to  $z$  do
5:    $[\text{pos}, \text{len}, \text{char}] \leftarrow f_i$ 
6:    $\text{Append output}[\text{pos}..\text{pos} + \text{len}]$  to output (repeatedly if fractured)
7:    $\text{Append char}$  to output
8: end for
9: return output

```

**Algorithmus 3.2:** LZ77-Decompression

In 3.2 wird die Dekompression einer Faktorenfolge in die ursprüngliche Zeichenfolge beschrieben. Für jeden Faktor wird chronologisch entweder ein einzelnes Zeichen oder eine referenzierte Teilfolge angefügt. Es kann jedoch sein, dass eine referenzierte Teilfolge über die bisher dekomprimierte Zeichenfolge geht. In diesem Fall muss der verfügbare Anteil durch Wiederholungen auf die geforderte Größe gestreckt werden.

### 3.3 Beispiel

#### 3.3.1 Uniforme Zeichenfolge

Als Eingabe dient die uniforme Zeichenfolge  $S = \text{aaaaaaaaa\$}$ .

1.  $i=1$ : [Grafik]
2.  $i=2$ : [Grafik]
3. Ergebnis:  $S = f_1 f_2$  mit  $f_1 = a$  und  $f_2 = \{pos = 1, len = 7, char = \$\}$

#### 3.3.2 Zeichenfolge mit Varianz

Als Eingabe dient die Zeichenfolge  $S = \text{abaabcabaab\$}$ .

1.  $i=1$ : [Grafik]
2.  $i=2$ : [Grafik]
3.  $i=3$ : [Grafik]
4.  $i=5$ : [Grafik]
5.  $i=7$ : [Grafik]
6. Ergebnis:  $S = f_1 f_2 f_3 f_4 f_5 f_6$  mit  $f_1 = a, f_2 = b, f_3 = \{1, 1, a\}, f_4 = \{2, 1, c\}, f_5 = \{1, 5, \$\}$



# Literaturverzeichnis

- [1] *The Canterbury Corpus*. <https://corpus.canterbury.ac.nz>.
- [2] *DEFLATE Compressed Data Format Specification version 1.3*. <https://www.rfc-editor.org/rfc/rfc1951.html>.
- [3] *Intel oneAPI Threading Building Blocks*. <https://www.intel.com/content/www/us/en/developer/tools/oneapi/onetbb.html>.
- [4] *OpenMP ARB*. <https://www.openmp.org>.
- [5] *STL Execution Policy*. [https://en.cppreference.com/w/cpp/algorithm/execution\\_policy\\_tag\\_t](https://en.cppreference.com/w/cpp/algorithm/execution_policy_tag_t).
- [6] E., OHLEBUSCH: *Lempel-Ziv Factorization: LZ77 without Window*. 2016.
- [7] FISCHER, JOHANNES, TRAVIS GAGIE, PAWEŁ GAWRYCHOWSKI und TOMASZ KOCIUMAKA: *Approximating LZ77 via Small-Space Multiple-Pattern Matching*. In: BANSAL, NIKHIL und IRENE FINOCCHI (Herausgeber): *Algorithms - ESA 2015*, Seiten 533–544. Springer Berlin Heidelberg, 2015.
- [8] KLEIN, SHMUEL TOMI und YAIR WISEMAN: *Parallel Lempel Ziv coding*. *Discrete Applied Mathematics*, 146(2):180–191, 2005. 12th Annual Symposium on Combinatorial Pattern Matching.
- [9] PROKOPEC, ALEKSANDAR, PHIL BAGWELL, TIARK ROMPF und MARTIN ODESKY: *A Generic Parallel Collection Framework*. In: JEANNOT, EMMANUEL, RAYMOND NAMYST und JEAN ROMAN (Herausgeber): *Euro-Par 2011 Parallel Processing*, Seiten 136–147, Berlin, Heidelberg, 2011. Springer Berlin Heidelberg.
- [10] SHAH, PARTH und RACHANA OZA: *Improved Parallel Rabin-Karp Algorithm Using Compute Unified Device Architecture*. In: SATAPATHY, SURESH CHANDRA und AMIT JOSHI (Herausgeber): *Information and Communication Technology for Intelligent Systems (ICTIS 2017) - Volume 2*, Seiten 236–244, Cham, 2018. Springer International Publishing.
- [11] WELCH: *A Technique for High-Performance Data Compression*. *Computer*, 17(6):8–19, 1984.

- [12] ZIV, J. und A. LEMPEL: *A universal algorithm for sequential data compression*. IEEE Transactions on Information Theory, 23(3):337–343, 1977.