Parallelisierung einer speichereffizienten Approximation der LZ77-Faktorisierung

Gajann Sivarajah

LZ-Kompression - Konzept

Eingabe: $S = e_1 \dots e_n$

- $e_i \in \Sigma = \{0, \dots, 255\}$

Ausgabe: $F = (f_1, \dots, f_z)$

- $f_1 \cdots f_z = S$
- $f_i = \begin{cases} (Länge, Position) & \text{, falls Referenz} \\ (0, Zeichen) & \text{, sonst} \end{cases}$

Algorithmus: $COMP_{LZ} : S \to F \iff DECOMP_{LZ} : F \to S$

LZ-Kompression - Gütemaße

Qualität:

- $FR = \frac{|F|}{|S|} \iff CR = \frac{|F_{Bin}|}{|S_{Bin}|}$

Perfomanz:

- $Speicher : \frac{Mem_{Peak}}{|S|}$
- $Zeit : T(|S|, P)$

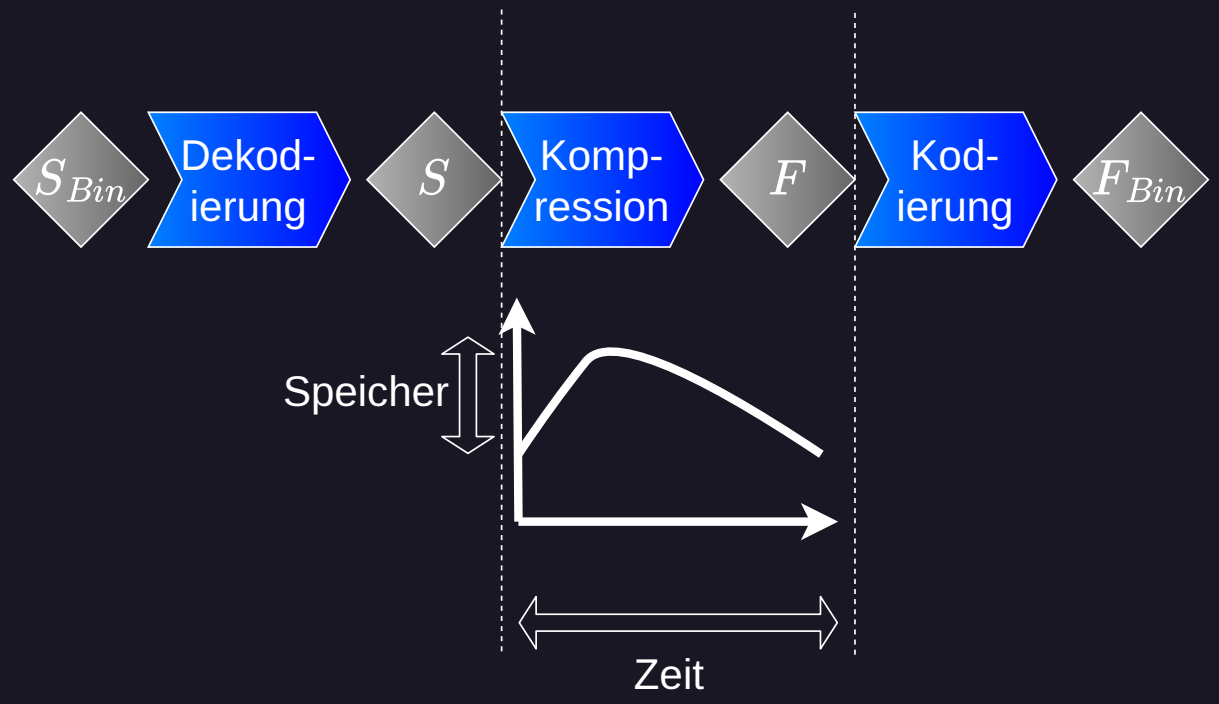

LZ77

Konzept:

- Scanne von links nach rechts
- Maximiere jeden Faktor $|f_i| \rightarrow Greedy$

Zeit / Speicher:

- Zeit: $O(n)$
- Speicher: $O(n)$

Approx. LZ77 - Konzept

Ablauf:

- Rundenbasierter Algorithmus
- Runde $r \Rightarrow$ Extrahiere Faktoren der Länge $\frac{|S|}{2^r}$
- Letzte Runde $r_{End} = \log |S| \Rightarrow$ Alle Zeichen sind faktorisiert

Approx. LZ77 - Konzept

Runde:

- (Noch unverarbeitete) Zeichenfolge in Blöcke aufteilen
- Unter den Blöcken Duplikate/Referenzen finden($InitTables$)
- Freie Suche nach Referenzen in S ($ReferenceScan$)
- Extrahiere Faktoren aus Referenzen

Approx. LZ77 - Konzept

InitTables

- Erzeuge $RFPTable$ und $RefTable$:
  - $RFPTable(RFP) = \text{Linkester Block mit RFP als Hash}$
  - $RefTable(Block) = \begin{cases} \text{Position einer Referenz zu } Block & \text{,falls bekann} \\ \text{Position von } Block & \text{, sonst} \end{cases}$
- Blöcke, die nicht in $RFPTable$ eingetragen werden $\Rightarrow$ **Faktoren**

Approx. LZ77 - Konzept

ReferenceScan

- Scan von links nach rechts $\Rightarrow$ Bewege RFP-Fenster
- Treffer in RFPTable + Links von Eintrag in RefTable $\Rightarrow$ **Faktor**

Approx. LZ77 - Güte

Zeit: $O(n \log n)$

Speicher: $O(z)$

Approx. LZ77Par - S $\Rightarrow$ Blöcke

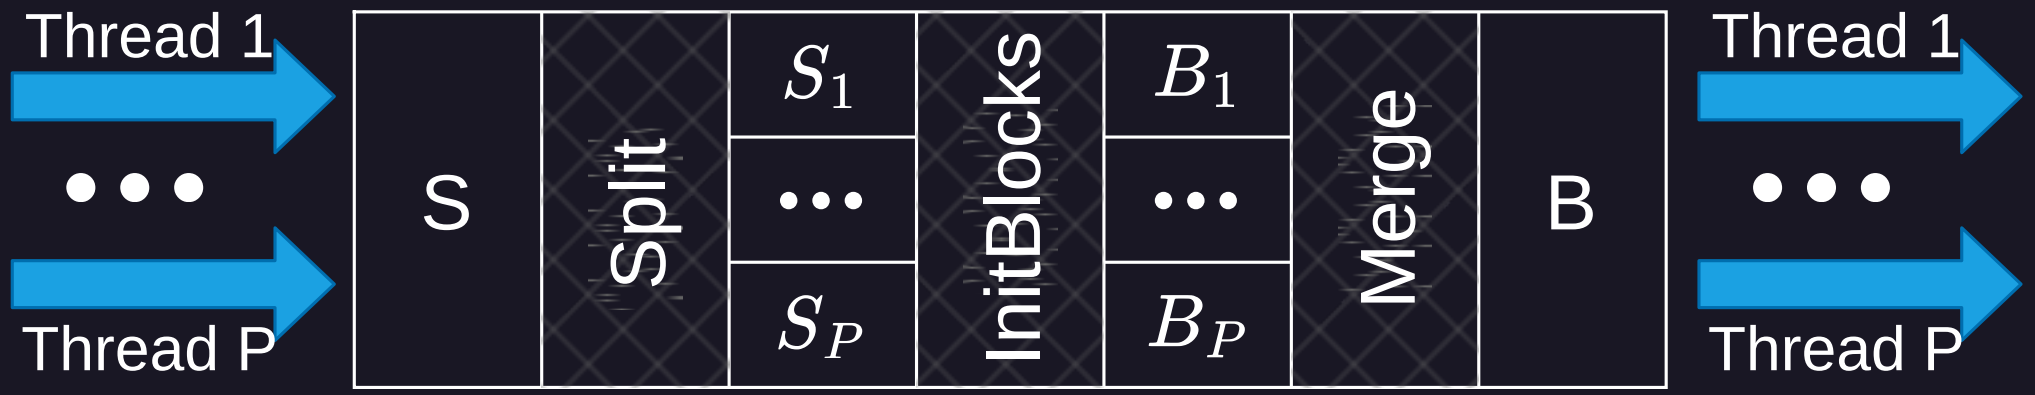

Approx. LZ77Par - InitTables

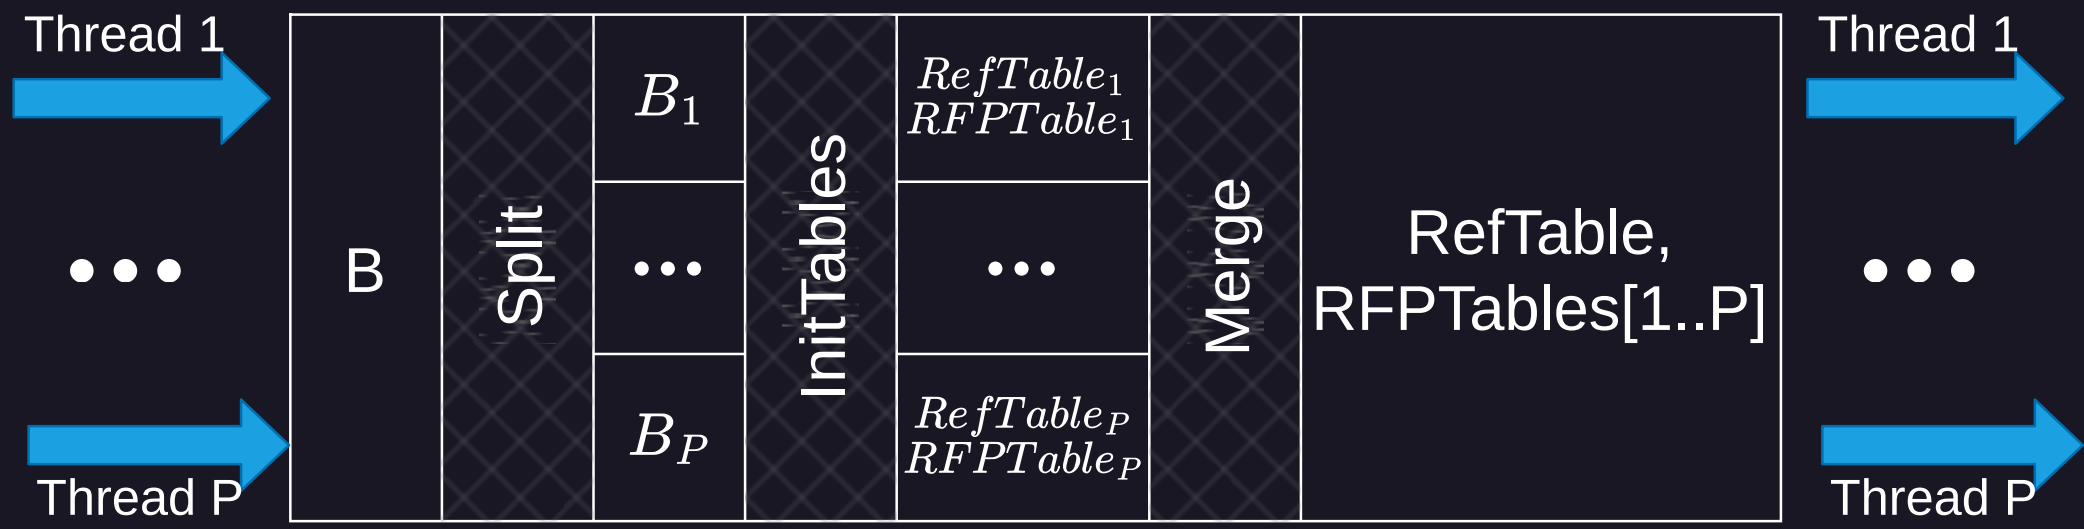

Approx. LZ77Par - ReferenceScan

Optimierungen - DynStart

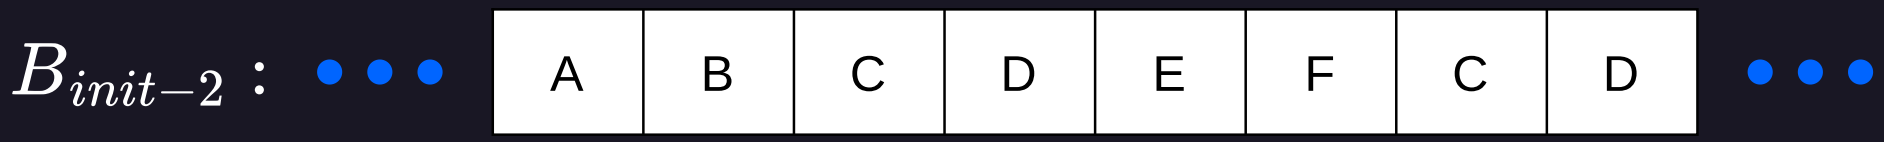

Optimierungen - DynStart

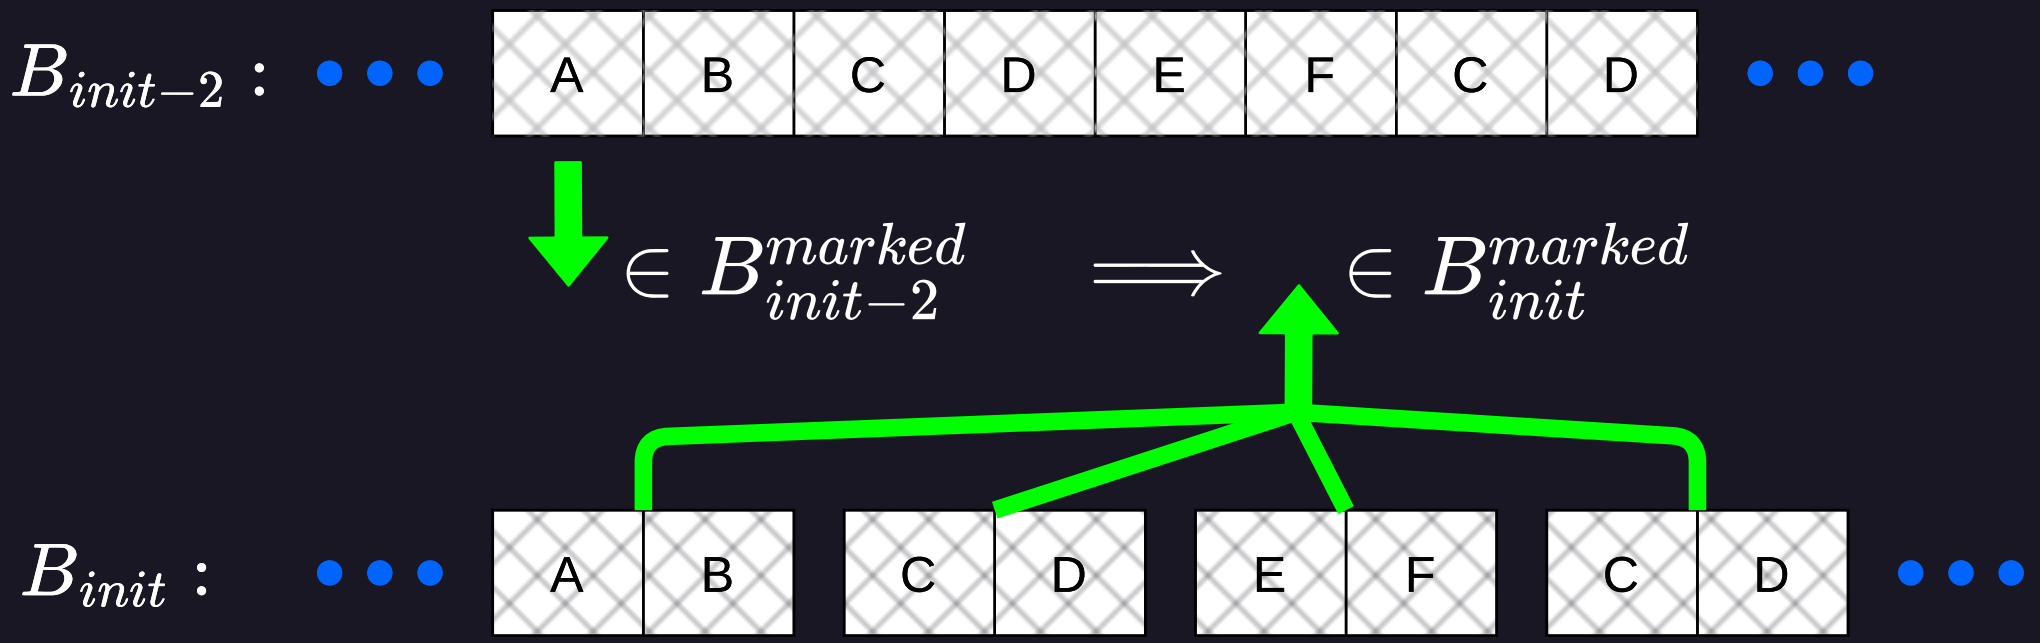

Optimierungen - DynStart

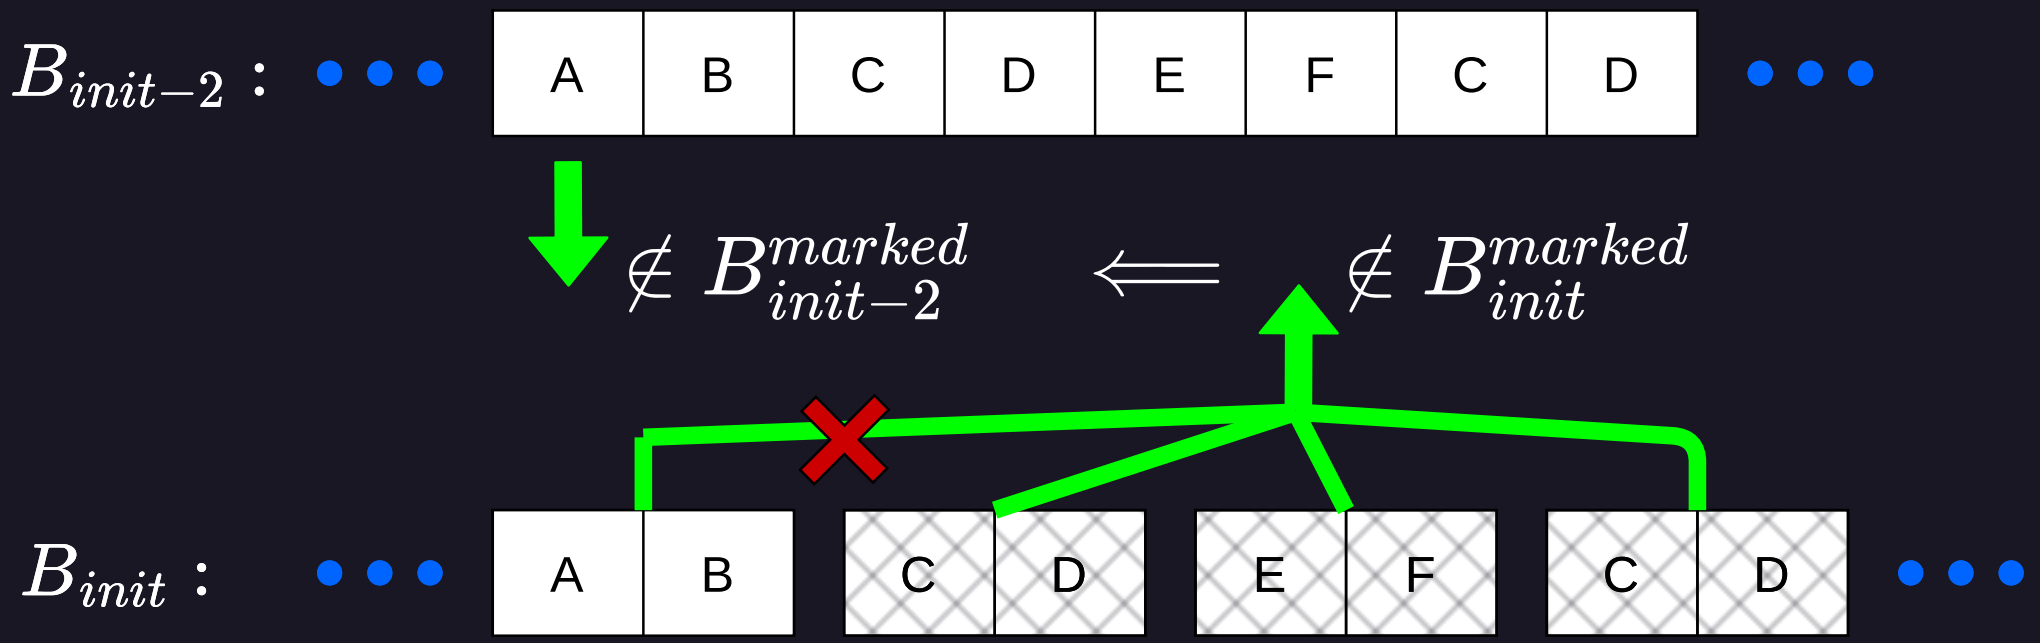

Optimierungen - DynEnd

- Kodierung $K_{OUT} : F \to \{0,1\}^*$
- $Min_{Ref} :=$ **Mindestanzahl Bits für referenzierenden Faktor**
- $Max_{Lit} :=$ **Maximale Bits für referenzloses Zeichen**
- Kodierung eines referenzierenden Faktors lohnt sich für mehr als $\lceil \frac{Min_{Ref}}{Max_{Lit}} \rceil$ referenzierte Zeichen

  $\Rightarrow$ Stoppe Algorithmus in Runde $\log |S| - \lceil \log \frac{Min_{Ref}}{Max_{Lit}} \rceil$

Optimierungen - PreMatching

- Auslassen?

Optimierungen - ScanSkip

- $|F_{ReferenceScan}| \leq |RFPTable| = |Blocks| - |F_{InitTables}|$
- $k = \frac{|RFPTable|}{|Blocks|}$
- **Führe ReferenceScan nur bei $k \geq k_{min} \in [0, 1]$ durch**

Evaluation - Qualität(FR)

COMP	proteins	sources	dna	xml	english
LZ77	9.95%	5.50%	6.66%	3.35%	6.66%
Approx. LZ77	15.34%	10.05%	10.71%	6.62%	10.42%
Approx. LZ77Par	15.34%	10.05%	10.71%	6.62%	10.42%

Evaluation - Speicher

COMP	proteins	sources	dna	xml	english
LZ77	14.88	13.44	13.44	12.72	13.44
Approx. LZ77	9.94	6.42	8.38	3.46	7.06
Approx. LZ77Par	10.21	5.90	6.66	3.46	6.16

Evaluation - Zeit - Sequentiell

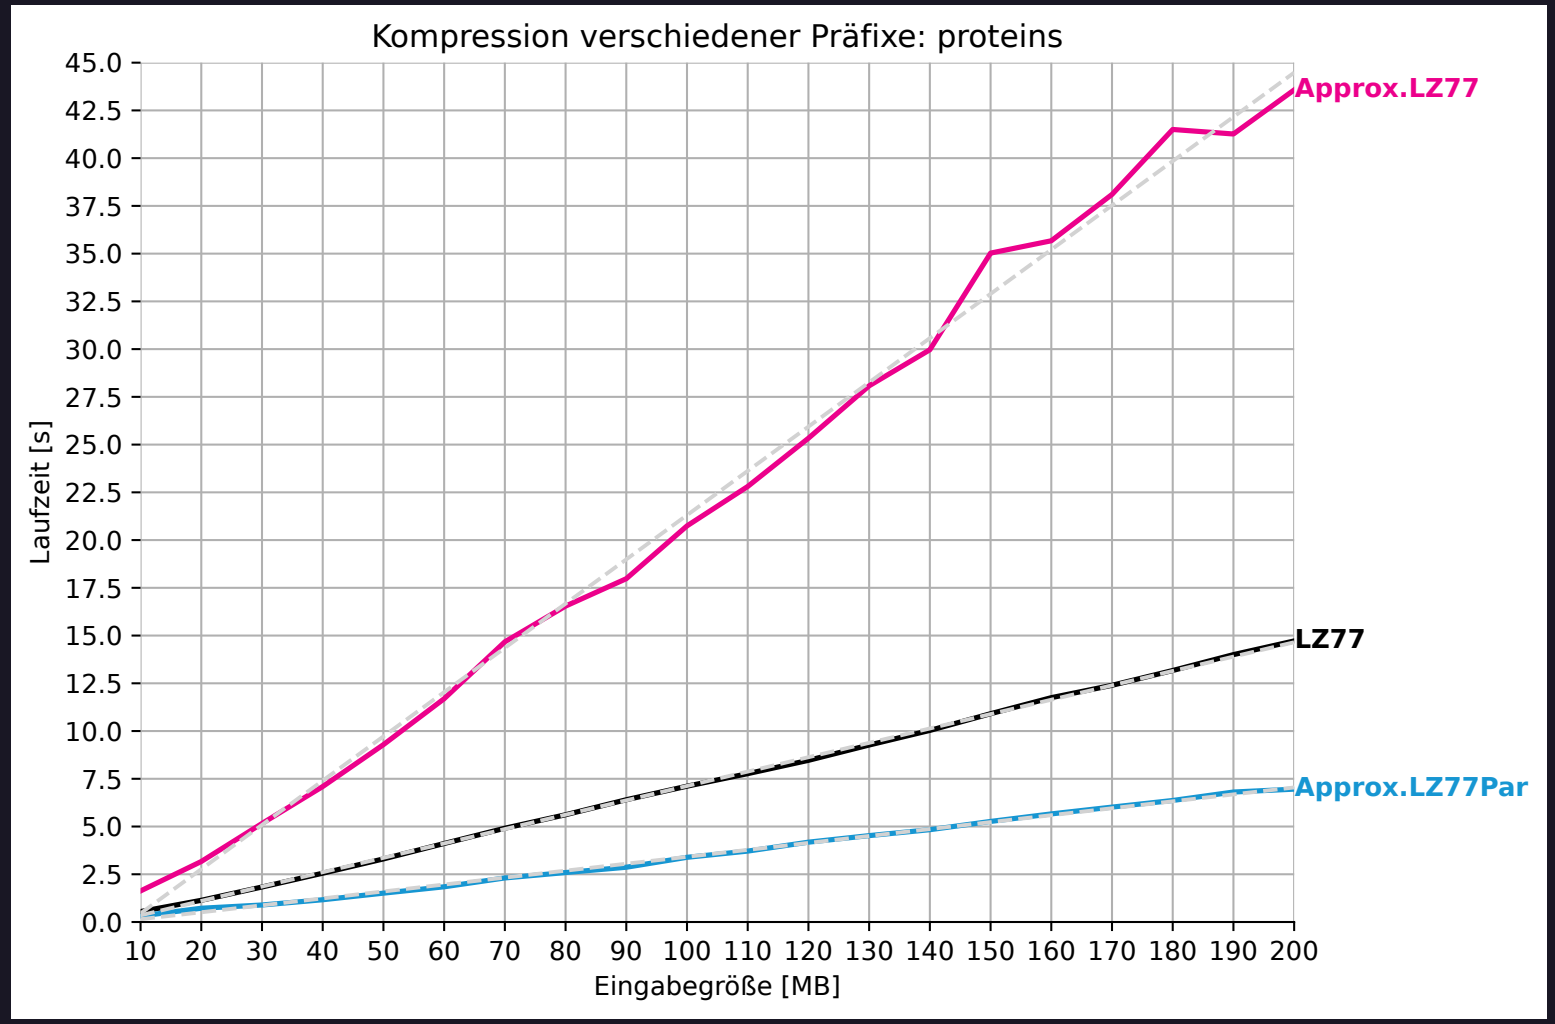

Evaluation - Zeit - Parallel

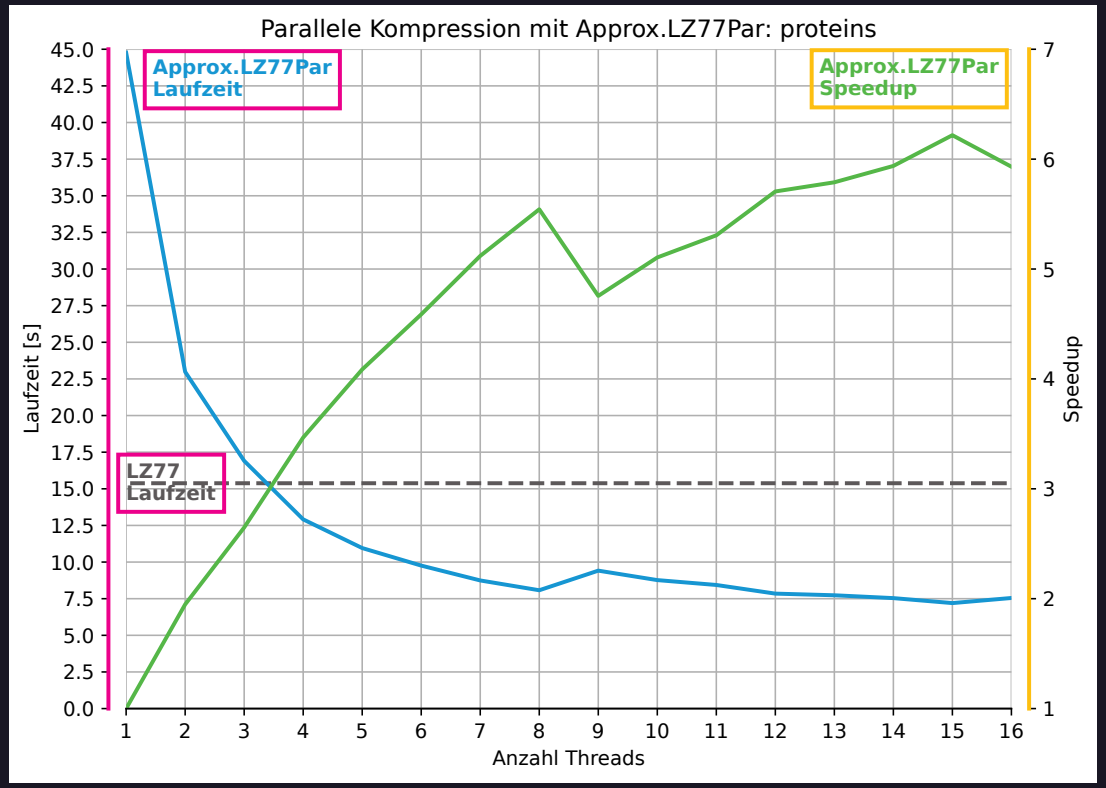

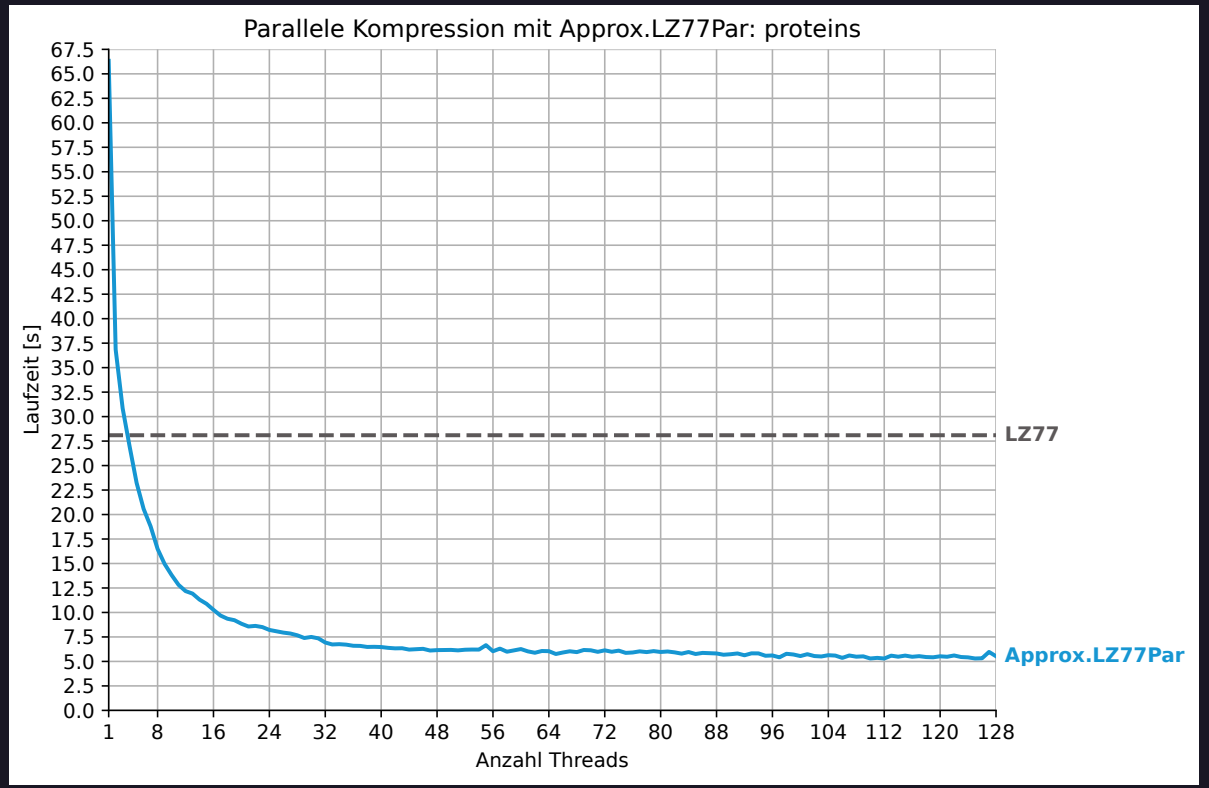

Evaluation - Optimierungen

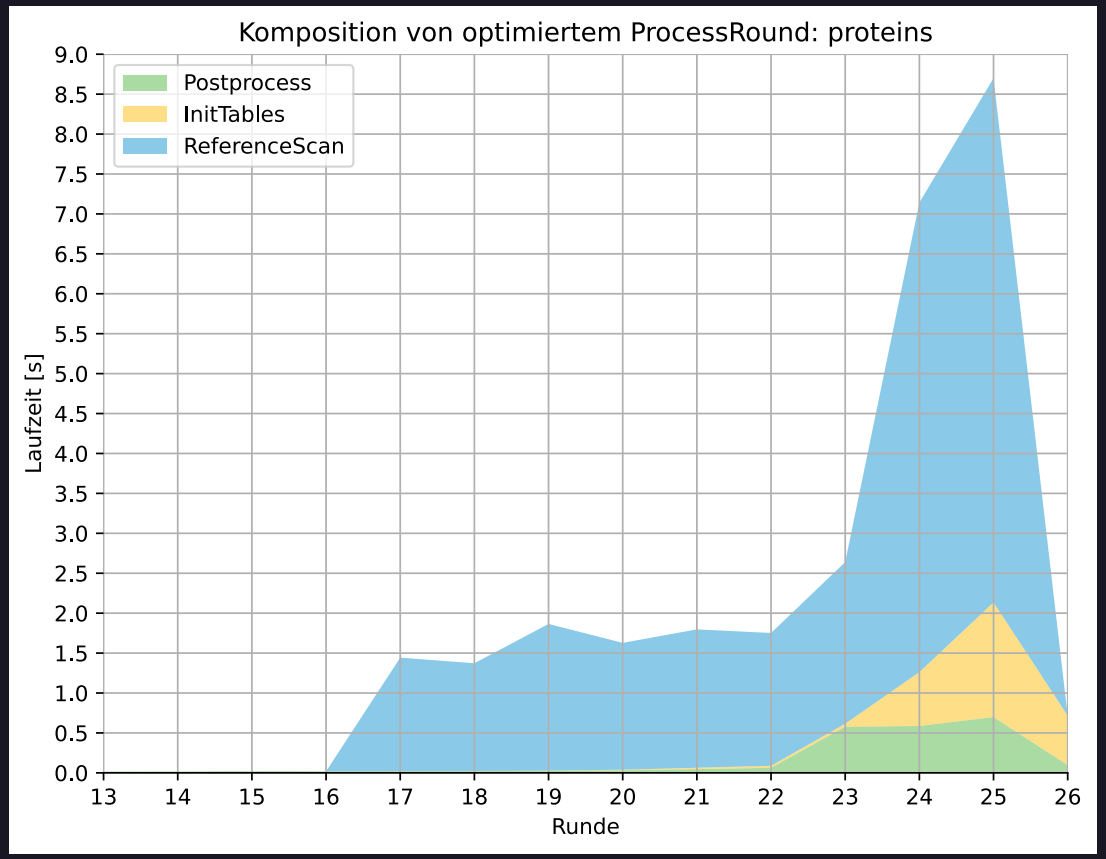

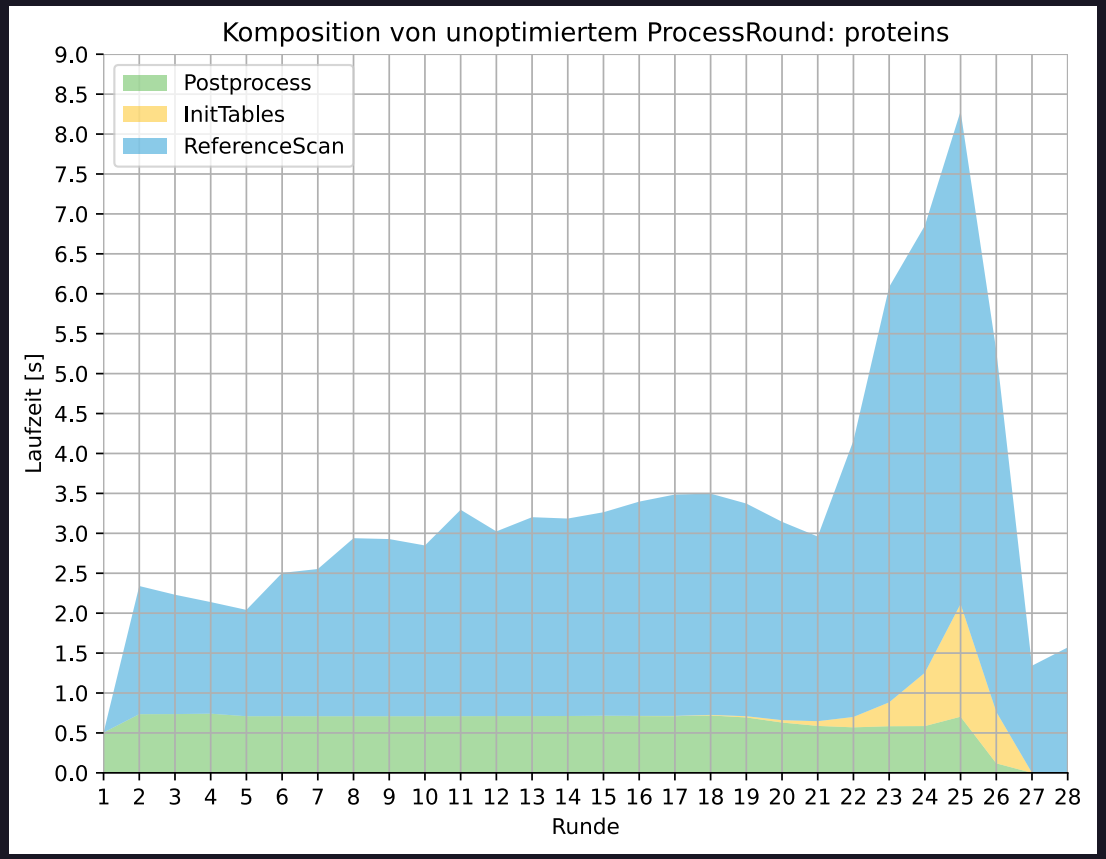

Fazit

Zusammenfassung

- Approx. LZ77 $\rightarrow$ Approx. LZ77Par : Korrektheit nachgewiesen
- Zeitersparnis durch Optimierungen stichprobenartig nachgewiesen
- Zeit(Approx. LZ77Par) $<$ Zeit(LZ77) $<$ Zeit(Approx. LZ77)
- Speicher(Approx. LZ77Par) $\approx$ Speicher(Approx. LZ77) $<$ Speicher(LZ77)

Offene Punkte

- Alternative Techniken (Hashtabelle, Bloom-Filter,...)
- Dynamische Generierung der Parameter $r_{PreMatch}$ und k_{min}
- Zweite und Dritte Phase des Approximationsalgorithmus